# SAGE: Learning Across Discontinuities

Certified Switching-Aware Differentiation for Nonconvex Neural-Symbolic Optimization

Đề xuất nghiên cứu hướng tới ICML 2027

Research proposal

Tháng 11 năm 2026

**Tóm tắt nội dung**

Các lớp tối ưu khả vi cho học neuro-symbolic thường sử dụng convexification hoặc smoothing để tích hợp các ràng buộc cứng vào mạng neural. Tuy nhiên, khi miền khả thi gồm nhiều thành phần hoặc chế độ logic cạnh tranh, nghiệm tối ưu có thể thay đổi không liên tục; gradient cục bộ có thể bằng không mặc dù một nhánh khác cho task loss thấp hơn. Đề xuất SAGE (Switching-Aware Gradients for Exact Neural-Symbolic Optimization) tách forward pass khả thi khỏi backward pass nhận biết chuyển nhánh. Phương pháp sử dụng projection theo nhánh, chứng nhận ổn định và loại bỏ nhánh cạnh tranh an toàn, kết hợp implicit differentiation với một hiệu chỉnh gradient dựa trên residual của smoothed task objective. Hướng phát triển chính là khai thác switching geometry và optimality bounds để giảm variance và số lần gọi global solver. Phạm vi lý thuyết ban đầu là hợp hữu hạn các miền lồi đóng, bao gồm ràng buộc phi tuyến lồi và các chế độ rời rạc; mở rộng sang miền phi lồi nội tại và rule activation không liên tục được xem là hướng tiếp theo. Các kết quả thực nghiệm và ưu thế về độ phức tạp là mục tiêu nghiên cứu, chưa phải kết quả đã xác lập.

## Mục lục

**1 Bối cảnh và khoảng trống nghiên cứu** **2**

1.1 Paper nền tảng: DisjunctiveNet . . . . . 2

1.2 Câu hỏi nghiên cứu trung tâm . . . . . 3

**2 Related work và positioning** **3**

**3 Motivation: discontinuity và gradient chết** **4**

**4 Problem formulation và phạm vi** **4**

**5 Proposed methodology: SAGE** **5**

5.1 Component 1: Exact branch-wise forward pass . . . . . 5

5.2 Component 2: Certified switching stability . . . . . 5

5.3 Component 3: Switching-aware gradient estimator . . . . . 6

5.4 Component 4: Geometry-aware boundary sampling . . . . . 6

5.5 Illustrative analytical example . . . . . 7

5.6 Training procedure . . . . . 7

**6 Theoretical contributions và proof plan** **7**

**7 Hierarchy: lồi, phi lồi, rời rạc và không liên tục** **8**

**8 Experimental design** **9**

8.1 E1: Controlled geometry benchmark . . . . . 9

8.2 E2: Gradient fidelity (core experiment) . . . . . 9

8.3 E3: Certification and scalability . . . . . 9

8.4 E4: Reproduce and extend DisjunctiveNet . . . . . 9

8.5 E5: Realistic hybrid applications . . . . . 9

8.6 E6: Ablation and failure analysis . . . . . 10

**9 Expected contributions và novelty statement** **10**

**10 Alternative directions** **10**

**11 Roadmap và go/no-go criteria** **11**

# 1 Bối cảnh và khoảng trống nghiên cứu

## 1.1 Paper nền tảng: DisjunctiveNet

DisjunctiveNet của Pal và Li (ICML 2026) [1] biểu diễn rules phụ thuộc input dưới dạng

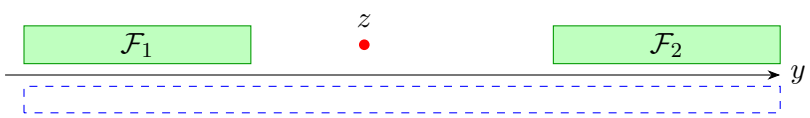
$$\mathbb{I}[x \in \mathcal{A}_r] \Rightarrow \mathbb{I}[y \in \mathcal{C}_r(x)], \qquad \mathcal{C}_r(x) = \bigcup_{j=1}^{m_r} \{y : A_{rj}(x)y \leq b_{rj}(x)\}. \tag{1}$$

Với tập rules đang active $\mathcal{R}(x)$, miền khả thi và lớp projection được định nghĩa

$$\mathcal{F}(x) = \bigcap_{r \in \mathcal{R}(x)} \mathcal{C}_r(x), \tag{2}$$

$$y^\star \in \arg\min_{y \in \mathcal{F}(x)} \|y - f_\theta(x)\|_1. \tag{3}$$

DisjunctiveNet lift objective vào không gian epigraph trước khi convexify, chuyển CNF sang DNF và sử dụng convex hull của các disjuncts. Với DNF đầy đủ và solver trả về nghiệm extreme point, nghiệm thỏa mãn các rules gốc. CNF/partial DNF giúp giảm chi phí nhưng không có bảo đảm tương đương trong trường hợp tổng quát. Backward pass dùng gradient của QP regularization trong khi forward sử dụng LP (Section 3.2). Paper cũng nêu nonlinear convex disjuncts và adaptive sequential convexification là future work (Section 5).




Convex hull chứa khoảng trống không khả thi

| Khía cạnh | DisjunctiveNet | Hướng phát triển |
|---|---|---|
| Miền lồi | Polyhedra | Convex nonlinear/conic |
| Miền phi lồi | Hợp polyhedra | Hợp miền cong, liên thông hoặc không liên thông |
| Biến rời rạc | MILP-representable | Hybrid discrete-continuous |
| Gradient | QP surrogate backward | Switching-aware differentiation |
| Scalability | DNF có thể tăng theo hàm mũ | Certified pruning và lazy search |

### 1.2 Câu hỏi nghiên cứu trung tâm

**Làm thế nào để duy trì output khả thi chính xác trong forward pass, đồng thời học được cách chuyển giữa các nghiệm tối ưu không liên tục mà không phải giải lại global optimization problem cho mọi perturbation?**

Novelty không nên chỉ là thay LP bằng QP/NLP, hay mở rộng ràng buộc tuyến tính sang phi tuyến. Các kỹ thuật đó là nền tảng triển khai, không phải đóng góp trung tâm.

## 2 Related work và positioning

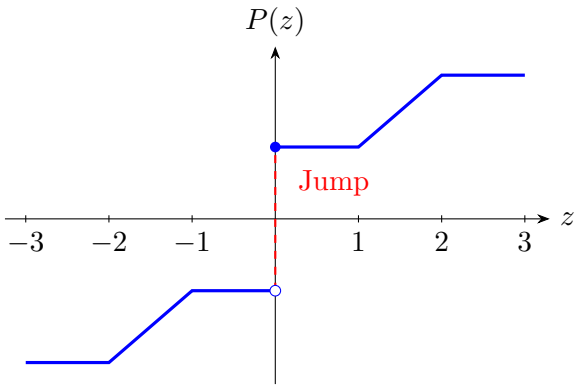
| Phương pháp | Venue | Liên quan và điểm cần phân biệt |
|---|---|---|
| DisjunctiveNet [1] | ICML 2026 | Hard logic tuyến tính; lifted convex hull, LP/QP backward. |
| DRL [2] | ICLR 2025 | Hard quantifier-free linear rules, kể cả miền không liên thông; refinement theo thứ tự biến. |
| Bisection Projection [3] | ICML 2025 | Projection trên compact sets có interior; bảo đảm phụ thuộc điều kiện về interior points. |
| FSNet [4] | NeurIPS 2025 | Feasibility-seeking cho bài toán lồi/phi lồi, smooth/nonsmooth. |
| IInet [5] | ICLR 2026 | Convex projection bằng operator splitting và implicit differentiation. |
| Generalized Stochastic Smoothing [6] | ICML 2026 | Gradient black-box và variance reduction; baseline chính cho estimator. |
| Perturbed Optimizers [7] | NeurIPS 2020 | Stochastic perturbation cho discrete optimization. |
| Reparameterization Gradient [8] | NeurIPS 2018 | Phân rã gradient vùng trơn và biên; cần phân biệt với SAGE. |
| OptNet/CVXPYLayers [9, 10] | ICML 2017 / NeurIPS 2019 | Differentiable convex optimization layers. |
| DC3 [11] | ICLR 2021 | Completion/correction cho constrained learning. |

Các hướng liên quan khác cần rà soát khi chốt manuscript gồm homeomorphic projection, Gauge Flow Matching, probabilistic hard constraints, first-order differentiation, Fiber Monte Carlo, hard-contact simulation và ShardNet. Đặc biệt, branch selection kết hợp differentiable projection, control variates và boundary-gradient decomposition đều có tiền lệ. **Không claim tính mới tuyệt đối của từng thành phần riêng lẻ.** Điểm khác biệt cần chứng minh là certified

reduction của switching computation, tận dụng trực tiếp geometry và bounds của optimizer, với forward giữ nguyên feasibility.

## 3 Motivation: discontinuity và gradient chết

Xét $\mathcal{F} = [-2,-1] \cup [1,2]$ và $P(z) \in \arg\min_{y\in\mathcal{F}} \frac{1}{2}(y-z)^2$. Khi $z \in (-1,0)$, $P(z) = -1$; khi $z \in (0,1)$, $P(z) = 1$. Tại $z = 0$, projection đa trị và mọi tie-breaking đơn trị đều tạo ra một jump.




Với $y_{\text{gt}} = 1.5$ và $z = -0.4$, $L(z) = (P(z) - 1.5)^2 = 6.25$ nhưng $\partial L/\partial z = 0$. Neural network không có tín hiệu chọn nhánh phải dù nhánh đó chứa target.

**Mệnh đề 1** (Topological obstruction)**.** *Nếu $\mathcal{Z}$ liên thông, $\mathcal{F} \subseteq \mathcal{Z}$ không liên thông, không tồn tại ánh xạ liên tục $P : \mathcal{Z} \to \mathcal{F}$ sao cho $P(y) = y$ với mọi $y \in \mathcal{F}$.*

*Chứng minh.* Ảnh của một tập liên thông qua ánh xạ liên tục phải liên thông. Điều kiện identity và codomain cho $P(\mathcal{Z}) = \mathcal{F}$, mâu thuẫn. □

Đây là hệ quả topology đã biết, không phải novelty toán học. SAGE sử dụng hệ quả này làm nguyên lý thiết kế: không ép hard projection liên tục toàn cục.

## 4 Problem formulation và phạm vi

Với input $x$ cố định trong quá trình differentiation, định nghĩa

$$\mathcal{F}(x) = \bigcap_{r\in\mathcal{R}(x)} \bigcup_{j=1}^{m_r} \mathcal{S}_{rj}(x), \tag{4}$$

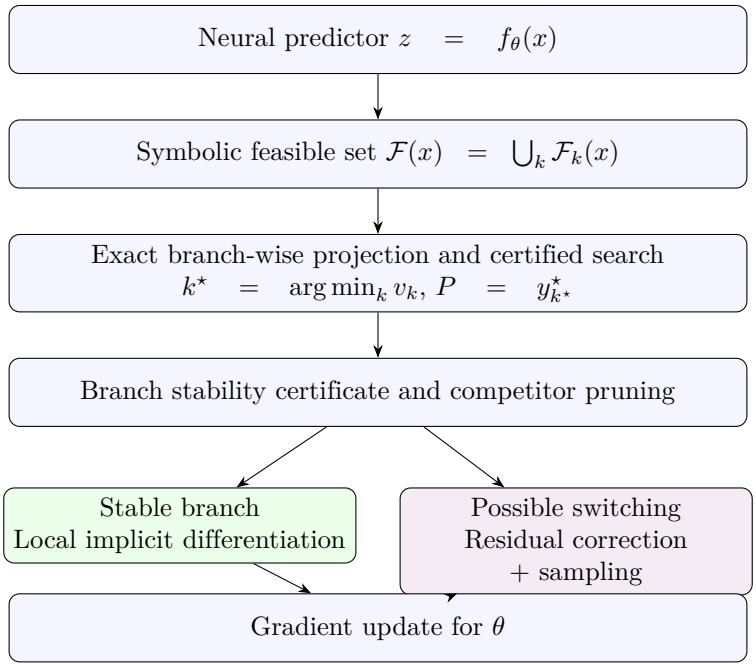
$$\mathcal{S}_{rj}(x) = \{y : g_{rj}(y,x) \le 0,\ h_{rj}(y,x) = 0\}, \tag{5}$$

$$\mathcal{F}(x) = \bigcup_{k\in\mathcal{K}(x)} \mathcal{F}_k(x). \tag{6}$$

Phạm vi chính: $\mathcal{K}(x)$ hữu hạn, mỗi branch không rỗng được giả định đóng, lồi; các nhánh rỗng được loại bỏ. Có thể sử dụng polyhedra, ellipsoids, SOCP-representable sets và các chế độ discrete cố định. Hợp các branch có thể phi lồi, không liên thông hoặc chồng lấn. Với nonlinear convex constraints, $g$ lồi và equality affine là một lựa chọn đủ để duy trì convexity.

**Phân biệt:** nonconvexity của tập, concavity của hàm, nonsmoothness và discontinuity của solution mapping là các khái niệm khác nhau. Chẳng hạn, $y^2 \ge 1$ có hàm liên tục nhưng miền không liên thông; ràng buộc $g(y) \ge 0$ với $g$ lõm lại xác định miền lồi. Miền có lỗ (annulus) có thể liên thông nhưng phi lồi, với projection đa trị ở tâm. Không phải mọi tập phi lồi đều biểu diễn chính xác bằng hữu hạn convex subsets.

# 5 Proposed methodology: SAGE




## 5.1 Component 1: Exact branch-wise forward pass

$$y^\star_k(z,x) = \arg\min_{y\in\mathcal{F}_k(x)} \tfrac{1}{2}\|y-z\|_2^2, \tag{7}$$

$$v_k(z,x) = \tfrac{1}{2}\|y^\star_k(z,x)-z\|_2^2, \tag{8}$$

$$k^\star(z,x) \in \arg\min_{k\in\mathcal{K}(x)} v_k(z,x), \tag{9}$$

$$P(z,x) = y^\star_{k^\star}(z,x). \tag{10}$$

Sử dụng tie-breaking xác định khi các branch có cùng cost. Với convex branches, projection riêng đơn trị; global projection có thể đa trị trước tie-breaking. Mỗi output vẫn thuộc miền khả thi gốc. Exact global optimality yêu cầu global branch solves và branch selection chính xác. Trong triển khai số, báo cáo feasibility tolerance và optimality gap; không coi nghiệm local NLP là global certificate.

## 5.2 Component 2: Certified switching stability

Đặt $d_k(z,x) = \mathrm{dist}(z,\mathcal{F}_k(x))$, $k_0 = k^\star(z,x)$ và

$$m(z,x) = \min_{j\neq k_0}[d_j(z,x) - d_{k_0}(z,x)]. \tag{11}$$

Mỗi distance function là 1-Lipschitz theo $z$. Nếu $m(z,x) > 2\rho$, thì $k_0$ vẫn là unique winning branch trong toàn bộ $\|w-z\|_2 \le \rho$. Các competitor có thể được giới hạn bằng

$$\mathcal{A}_\rho(z,x) = \{j : d_j(z,x) - d_{k_0}(z,x) \le 2\rho\}. \tag{12}$$

Nếu $L_j \le d_j(z,x)$ và $U_0 \ge d_{k_0}(z,x)$ là certified bounds, điều kiện $L_j - U_0 > 2\rho$ đủ để prune branch $j$. Với implicit DNF, lower bounds trên partial assignments cho phép prune cả nhóm nhánh. Chứng nhận phải tính cho toàn bộ nhánh chưa duyệt, không chỉ top-$K$ dự đoán.

### 5.3 Component 3: Switching-aware gradient estimator

Đặt $L(w) = \ell(P(w, x), y_{\text{gt}})$. Chọn smooth density $q$ có support trong unit ball, với $u \sim q$ và

$$J_\rho(z) = \mathbb{E}_u[L(z + \rho u)]. \tag{13}$$

Mỗi perturbed forward vẫn khả thi. Không sử dụng $\ell(\mathbb{E}[P(z+\rho u)], y_{\text{gt}})$, vì trung bình nghiệm có thể không khả thi.

Giữ reference branch $k_0$ cố định trong phép differentiation tại $z$; định nghĩa

$$L_0(w) = \ell(y^\star_{k_0}(w, x), y_{\text{gt}}), \tag{14}$$
$$R_0(w) = L(w) - L_0(w), \tag{15}$$
$$s_q(u) = -\nabla_u \log q(u). \tag{16}$$

Với các điều kiện regularity thích hợp, gradient decomposition được viết

$$\boxed{\nabla J_\rho(z) = \mathbb{E}_u[\nabla L_0(z + \rho u)] + \frac{1}{\rho}\mathbb{E}_u[R_0(z + \rho u)s_q(u)].} \tag{17}$$

Thành phần thứ nhất là within-branch gradient (implicit differentiation hoặc projection Jacobian a.e.). Thành phần thứ hai là switching correction. Khi certificate $m > 2\rho$ đúng, $R_0 = 0$ trên toàn bộ support, do đó không cần global perturbed solves. Lưu ý gradient của smoothed local objective vẫn là expectation, không mặc nhiên bằng gradient tại center.

Một estimator Monte Carlo với $N$ samples là

$$\widehat{G} = \frac{1}{N}\sum_{i=1}^{N}\left[\nabla L_0(z + \rho u_i) + \frac{R_0(z + \rho u_i)s_q(u_i)}{\rho}\right]. \tag{18}$$

Có thể dùng independent samples cho hai thành phần hoặc control variates để giảm variance. Đây là gradient của $J_\rho$, không phải classical gradient của discontinuous $L$ tại jump.

### 5.4 Component 4: Geometry-aware boundary sampling

Với các branch convex, xác định switching surface

$$\mathcal{B}_{ij}(x) = \{z : v_i(z, x) = v_j(z, x) \le v_k(z, x),\ \forall k\}. \tag{19}$$

Từ gradient của squared distance,

$$\nabla_z v_k = z - y^\star_k, \tag{20}$$
$$\nabla_z(v_i - v_j) = y^\star_j - y^\star_i. \tag{21}$$

Tại regular boundary, vector $n_{ij} = (y^\star_j - y^\star_i)/\|y^\star_j - y^\star_i\|_2$ cung cấp hướng normal. Khi hai nghiệm trùng nhau hoặc gradient hiệu cost bằng không, cần fallback thay vì dùng normal không xác định.

Hướng phát triển chính: proposal density $p_z(u)$ tập trung quanh các switching regions khả dĩ, có support bao phủ $q$ (ví dụ mixture $p_z = (1-\alpha)q + \alpha p_{\text{focus}}$, $0 \le \alpha < 1$). Với importance weighting $q(u)/p_z(u)$, switching correction vẫn unbiased nếu các điều kiện integrability được thỏa mãn. Khi estimate gradient tại $z$, không differentiate qua adaptive sampling density như một phần của objective. Cần so sánh variance và chi phí với isotropic perturbation và variance reduction hiện có [6].

### 5.5 Illustrative analytical example

Quay lại $\mathcal{F} = [-2, -1] \cup [1, 2]$, $y_{\text{gt}} = 1.5$. Trong khoảng gap, loss trái/phải lần lượt bằng 6.25 và 0.25. Dùng uniform perturbation $\delta \sim U[-\rho, \rho]$ để minh họa (không sử dụng score formula của smooth density cho uniform). Nếu $|z| < \rho$ và $|z| + \rho < 1$, ta có

$$J_\rho(z) = 3.25 - \frac{3z}{\rho}, \qquad \frac{dJ_\rho}{dz} = -\frac{3}{\rho}. \tag{22}$$

Gradient hướng sang branch phải dù hard gradient bằng không. Nếu support không chạm switching boundary, correction có thể vẫn bằng không. Radius scheduling theo margin hoặc exploration có thể cần thiết; nếu $\rho$ thay đổi theo $z$, phải xác định rõ objective và các đạo hàm bổ sung, hoặc coi $\rho$ là hyperparameter cố định ở từng bước.

### 5.6 Training procedure

1. Với mỗi $(x, y_{\text{gt}})$, tính $z = f_\theta(x)$ và solve center projection, lấy winner, incumbent và bounds.
2. Tạo competitor set bằng certificate; prune các nhóm branch có lower bound đủ lớn.
3. Sample perturbations; solve reference branch, và nếu không chứng nhận ổn định thì solve trên các competitor còn lại để xác định exact winner.
4. Tính local Jacobian và residual correction theo (17); có thể dùng boundary-focused importance sampling.
5. Backpropagate $\widehat{G}$ qua $f_\theta$ và cập nhật $\theta$. Inference chỉ dùng hard projection tại center, không lấy trung bình output.

## 6 Theoretical contributions và proof plan

**Định lý 1** (Feasibility and global projection)**.** *Nếu $\mathcal{F}(x)$ là hợp hữu hạn các closed nonempty branches và từng branch được giải toàn cục, winner có chi phí nhỏ nhất trả về global Euclidean projection. Nếu chỉ có feasible incumbents, output vẫn khả thi nhưng global optimality không được bảo đảm.*

*Chứng minh.* Mỗi điểm thuộc ít nhất một branch; minimum của objective trên union bằng minimum của các branch minima. □

**Định lý 2** (Certified branch stability)**.** *Nếu $m(z, x) > 2\rho$, mọi perturbation $\|w - z\|_2 \le \rho$ giữ nguyên unique winning branch $k_0$.*

*Chứng minh.* Triangle inequality cho $d_j(w) - d_{k_0}(w) \ge d_j(z) - d_{k_0}(z) - 2\rho > 0$ với mọi $j \ne k_0$. □

**Định lý 3** (Unbiased gradient of smoothed loss)**.** *Giả sử $q \in C_c^1(\mathbb{R}^d)$, $L$ locally bounded/measurable, $L_0$ locally Lipschitz và các expectations hữu hạn. Khi đó (17) đúng tại $z$, với $k_0$ giữ cố định. Monte Carlo estimator tương ứng unbiased đối với $\nabla J_\rho(z)$.*

*Proof sketch.* Viết convolution của $L = L_0 + R_0$ với scaled density. Với $L_0$, differentiation under expectation cho a.e. derivative nhờ local Lipschitzness. Với $R_0$, chuyển đạo hàm sang kernel và dùng compact support, thu được score term $-\nabla q/q$ trên $q > 0$. □

**Variance và oracle complexity (mục tiêu chính, chưa chứng minh ưu thế tổng quát).** Đặt $p_{\mathrm{sw}} = \Pr(k^\star(z+\rho u, x) \neq k_0)$. Nếu $|R_0| \leq M$, correction có second moment

$$\mathbb{E}\|\widehat{G}_{\mathrm{switch}}\|^2 \leq \frac{M^2}{\rho^2}\mathbb{E}[\|s_q(u)\|^2 \mathbb{I}_{\mathrm{sw}}]. \tag{23}$$

Với $\|s_q\| \leq C$ trên switching event, vế phải không vượt quá $M^2C^2p_{\mathrm{sw}}/\rho^2$. Smooth compact-support densities có thể có unbounded score gần biên; cần weighted moment bounds thích hợp, không giả định bounded score tùy tiện. Với $N$ perturbations và tỷ lệ center được chứng nhận $p_{\mathrm{cert}}$, số perturbed global calls có thể giảm từ $N$ xuống $N(1-p_{\mathrm{cert}})$ trung bình, chưa tính center, certificate, local solves và chi phí tìm bounds. Cần chứng minh/đo total cost và variance của estimator đầy đủ (bao gồm covariance), không suy diễn từ bound của riêng correction.

Mục tiêu theory mạnh hơn: bound phụ thuộc số competitor còn lại, switching geometry, certificate coverage và solver complexity; xây dựng proposal giúp giảm variance dưới matched oracle budget so với black-box smoothing. Các mệnh đề cơ bản ở trên là tiền đề, không đủ để tự tạo novelty ICML.

# 7 Hierarchy: lồi, phi lồi, rời rạc và không liên tục

| Level | Problem class | Phạm vi bảo đảm |
|---|---|---|
| 1. Convex | Một closed convex branch | Projection đơn trị; chỉ local gradient. |
| 2. Union of convex sets | Hợp ellipsoids/polyhedra, mixed modes | Core: global projection, certified switching và smoothed gradient. |
| 3. Intrinsically nonconvex | Annulus, AC-OPF, nonlinear equality | Cần specialized global solver hoặc spatial B&B; internal switching không được certificate liên-branch xử lý tự động. |
| 4. Discontinuous rules | Input-triggered mode activation, learnable thresholds | Với $x$ cố định, core áp dụng; differentiation theo threshold/input cần theory mới cho branch birth/death. |

Ví dụ hybrid: $u \in \{0,1\}$, $u = 0 \Rightarrow y = 0$, $u = 1 \Rightarrow y_{\min} \leq y \leq y_{\max}$. Ví dụ activation: $x > \tau \Rightarrow y \geq a$. Cần phân biệt output-induced switching theo $z$ với input-induced switching do chính $\mathcal{F}(x)$ thay đổi. Nếu rules mâu thuẫn làm miền rỗng, không thể bảo đảm feasibility; cần báo cáo tỷ lệ infeasible inputs và xử lý bằng abstention hoặc conflict resolution riêng.

# 8 Experimental design

## 8.1 E1: Controlled geometry benchmark

| Family | Geometry | Controlled factors |
|---|---|---|
| Convex polytope | Lồi, liên thông | Dimension, constraint count |
| Ellipsoid | Convex nonlinear | Curvature |
| Union of ellipsoids | Connected/disconnected | Overlap, gap |
| Separated regions | Disconnected | Branch separation |
| Annulus/U-shaped | Intrinsic nonconvex | Hole/concavity; specialized solver |
| Hybrid/discrete | Mixed modes | Mode count, separation |

Đánh giá $d \in \{2, 10, 50, 100\}$ và $K \in \{2, 4, 8, 16, 32, 64\}$ theo controlled slices, không cần full Cartesian product. Thay đổi gap, tỷ lệ near-boundary samples, initialization vào wrong branch và data size. Metrics: MSE, CSAT, optimality gap, branch-selection accuracy, gradient-dead rate và solver calls.

## 8.2 E2: Gradient fidelity (core experiment)

So sánh với analytic reference hoặc high-accuracy numerical reference của cùng smoothed objective. Báo cáo bias, variance, cosine similarity, solver calls và training progress.

$$\text{GradSim} = \frac{\langle \widehat{g}, g_{\text{ref}} \rangle}{\|\widehat{g}\|_2 \|g_{\text{ref}}\|_2}. \tag{24}$$

Khi reference gradient bằng không, báo cáo norm error thay cosine. Baselines: hard branch KKT, DisjunctiveNet QP surrogate (trên setting tương thích), STE, perturbed optimizers, generalized stochastic smoothing với variance reduction, SAGE. Đánh giá gradient error với matched smoothing distribution/radius; đối với surrogate objective khác, ghi rõ sự khác biệt.

## 8.3 E3: Certification and scalability

Tăng số rules, disjuncts và branch groups. Đo certificate rate, pruning rate, number of global/local solver calls, forward/backward time, memory và optimality gaps. Biểu đồ chính: test/training loss versus total global solver calls và total wall-clock time. So sánh matched budget, bao gồm overhead của certificate và proposal.

## 8.4 E4: Reproduce and extend DisjunctiveNet

Tái tạo synthetic cooling-control và PBMC3k classification từ [1]; đánh giá IID/OOD và data-scarce regimes. Mở rộng cooling control bằng nonlinear operating envelopes và discrete equipment modes. PBMC3k là benchmark kế thừa linear logic, không phải bằng chứng chính cho general nonconvexity. Tách consistent inputs khỏi conflicting rules và báo cáo tỷ lệ conflict.

## 8.5 E5: Realistic hybrid applications

- **Robot motion planning:** nhiều hành lang hoặc trajectory modes; convex corridors cho core theory, kiểm tra collision và continuity giữa các trajectory waypoints. Không đánh đồng feasibility tại waypoints với collision-free toàn trajectory.

- **Hybrid energy management:** charge/discharge, on/off generators, nonlinear convex operating regions; đo cost, mode choice và constraint satisfaction.
- **AC-OPF (extension):** nonconvex power-flow equalities; báo cáo residual và optimality certificates nếu có. Local feasibility không đồng nghĩa global optimality.

Ưu tiên hai ứng dụng đầu; AC-OPF chỉ triển khai khi có solver và thời gian phù hợp.

### 8.6 E6: Ablation and failure analysis

| Variant | Research question |
|---|---|
| Without switching correction | Local gradient mắc kẹt ở sai branch? |
| Without certificates | Giảm chi phí bao nhiêu? |
| Without pruning | Hiệu quả khi số branches tăng? |
| Isotropic sampling | Boundary-focused proposal có giảm variance? |
| Fixed radius | Sensitivity của smoothing radius? |
| Soft branch averaging | Feasibility bị mất khi averaging? |

Báo cáo tối thiểu 5 seeds, confidence intervals, paired comparisons, matched budgets và failure cases: solver errors, wrong branch, tie/degenerate boundaries, small radius, high-dimensional perturbations, infeasible inputs. Kết quả hiện chưa có.

## 9 Expected contributions và novelty statement

- A switching-aware differentiable optimization framework for neural-symbolic learning over input-dependent unions of convex feasible sets, preserving exact feasibility without imposing global continuity on the optimal solution mapping.
- Certified branch-stability and competitor-pruning mechanisms that identify when branch-local differentiation suffices and when competing solutions must be considered.
- A structure-aware gradient estimator combining branch-local differentiation with switching corrections, targeting unbiased estimation of a well-defined smoothed task objective and reduced global solver calls.
- A theoretical and empirical characterization of the trade-off among feasibility, gradient fidelity, variance, and computational cost on geometric, nonlinear, and hybrid learning tasks.

**Proposed novelty statement.** Rather than smoothing away discrete solution transitions or treating the optimizer as a black box, we exploit the geometry and optimality bounds of competing solutions to certify when switching is impossible, identify relevant competitors, and compute structure-aware gradients while preserving exact feasibility. Các claims về variance reduction, scalability và empirical superiority là giả thuyết cần kiểm chứng. Cần đối chiếu kỹ với control-variate estimators, boundary-gradient methods và các paper 2026 trước khi chốt novelty claim.

## 10 Alternative directions

**Topology-aware feasible neural operators.** Học một atlas các feasible charts $y = T_k(x, u)$ với discrete chart selector; novelty cần đến từ coverage certificates và input-dependent topology, không chỉ mixture-of-experts với invertible networks.

**Adaptive certified convexification.** Rule-interaction graph chọn các rules cần gộp vào DNF dựa trên violation, dual information và relaxation gap. Dừng khi có feasibility/optimality

certificate. Đây là future direction của DisjunctiveNet nên cần cơ chế mới ngoài việc học thứ tự basic steps. Nên dùng như thành phần lazy search hỗ trợ SAGE thay vì một paper thứ hai trong cùng manuscript.

## 11 Roadmap và go/no-go criteria

| Giai đoạn | Công việc | Điều kiện tiếp tục |
|---|---|---|
| 1. Prototype | Intervals, ellipsoids, QP branches | Gradient fidelity và khả năng thoát wrong branch |
| 2. Core theory | Certificate, residual estimator, safe pruning | Proof và reproducible numerical validation |
| 3. Efficiency | Boundary sampling, lazy search | Giảm variance hoặc total computation ở matched budget |
| 4. Applications | Cooling, PBMC3k, robot, energy | Feasibility và chất lượng học cạnh tranh |
| 5. Manuscript | Ablations, limitations, reproducibility | Novelty rõ so với các công trình gần nhất |

**Kết luận.** Hướng đề xuất là certified differentiation across optimizer-induced discontinuities. Phạm vi khả thi nhất cho ICML 2027 là finite union of closed convex sets (bao gồm nonlinear convex branches), với intrinsic nonconvexity và trainable discontinuous rules là extensions. Điểm quyết định không phải thêm constraint families mà là chứng minh và thực nghiệm rằng optimizer structure giúp học qua discontinuity hiệu quả hơn mà không làm mất exact feasibility.

## Tài liệu


[1] S. Pal and C. Li. DisjunctiveNet: Neural Symbolic Learning via Differentiable Convexified Optimization Layers. ICML, 2026. https://proceedings.mlr.press/v306/pal26a.html.

[2] M. C. Stoian and E. Giunchiglia. Beyond the Convexity Assumption: Realistic Tabular Data Generation under Quantifier-Free Real Linear Constraints. ICLR, 2025. https://proceedings.iclr.cc/paper_files/paper/2025/hash/47360925c45a166c96f652589265dee9-Abstract-Conference.html.

[3] E. Liang and M. Chen. Efficient Bisection Projection to Ensure Neural-Network Solution Feasibility for Optimization over General Set. ICML, 2025. https://proceedings.mlr.press/v267/liang25b.html.

[4] H. Nguyen and P. Donti. FSNet: Feasibility-Seeking Neural Network for Constrained Optimization with Guarantees. NeurIPS, 2025. https://papers.nips.cc/paper_files/paper/2025/hash/3874e2be479a9d4e94d4514046c1f934-Abstract-Conference.html.

[5] P. D. Grontas, A. Terpin, E. Balta, R. D'Andrea, and J. Lygeros. Πnet: Optimizing Hard-Constrained Neural Networks with Orthogonal Projection Layers. ICLR, 2026. https://proceedings.iclr.cc/paper_files/paper/2026/hash/66ba03db7e50b5db5593fe759527a74f-Abstract-Conference.html.

[6] F. Petersen, C. Borgelt, A. A. Mishra, and S. Ermon. Generalizing Stochastic Smoothing for Differentiation and Gradient Estimation. ICML, 2026. https://proceedings.mlr.press/v306/petersen26a.html.

[7] Q. Berthet, M. Blondel, O. Teboul, M. Cuturi, J.-P. Vert, and F. Bach. Learning with Differentiable Perturbed Optimizers. NeurIPS, 2020.

[8] W. Lee, H. Yu, and H. Yang. Reparameterization Gradient for Non-differentiable Models. NeurIPS, 2018.

[9] B. Amos and J. Z. Kolter. OptNet: Differentiable Optimization as a Layer in Neural Networks. ICML, 2017. https://proceedings.mlr.press/v70/amos17a.html.

[10] A. Agrawal, B. Amos, S. Barratt, S. Boyd, S. Diamond, and J. Z. Kolter. Differentiable Convex Optimization Layers. NeurIPS, 2019.

[11] P. L. Donti, D. Rolnick, and J. Z. Kolter. DC3: A Learning Method for Optimization with Hard Constraints. ICLR, 2021.